

Lineare Regression mit Basisfunktionen

- » Zusammenhang zwischen Inputs x und Outputs y wird modelliert durch:

$$y = a_0 + \sum_{j=1}^p a_j B_j(x) + \varepsilon$$

- » Hier sind B_j Basis Funktionen die frei gewählt werden können und a_j die Koeffizienten die wir an die Daten anpassen wollen.
- » Die **optimalen Koeffizienten** sind gegeben durch

$$\hat{a} = (B^T B)^{-1} B^T y$$

Bias-Variance Trade-Off and Regularization




FH KUFSTEIN TIROL
University of Applied Sciences

Ziel:

- Einerseits: Modell funktioniert sehr gut auf den vorhandenen Trainingsdaten -> **Datenfit**
 - Andererseits: Modellvorhersagen sind auch auf ungesehen Testdaten qualitative hochwertig -> **Generalisierung**
- » Generell ist es **nicht möglich** beides gleichzeitig perfekt zu erfüllen

Bias-Variance Tradeoff

- » Der Fehler eines Modells $\hat{f}$ kann wie folgt in drei Teile zerlegt werden:



- » Gegen den irreduziblen Fehler können wir nichts unternehmen.

Formel (nur für interessierte)

- » Wir wollen den mean-squared den Fehler des geschätzten Modells $\hat{f}$ gegenüber dem wahren Modell f analysieren:

$$\begin{aligned}\text{MSE}(x) &= \mathbb{E}[(y - \hat{f}(x))^2] \\ &= \mathbb{E}[(f(x) + \varepsilon - \hat{f}(x))^2]\end{aligned}$$

$$= \mathbb{E}[(f(x) - \hat{f}(x))^2] + 2\mathbb{E}[(f(x) - \hat{f}(x))\varepsilon] + \mathbb{E}[\varepsilon^2]$$

- » Der letzte Term ist schon der irreduzible Fehler für den $\mathbb{E}[\varepsilon^2] = \sigma^2$ gilt.
- » Der zweite Term verschwindet unter der Standardannahme $\mathbb{E}[\varepsilon] = 0$, da das Rauschen unabhängig von x ist.

Formel (nur für interessierte)

» Wir haben also:

$$\text{MSE}(x) = \mathbb{E}[(f(x) - \hat{f}(x))^2] + \sigma^2$$

» Wir zerlegen nun den ersten Term:

$$\begin{aligned} \mathbb{E}[(f(x) - \hat{f}(x))^2] &= \mathbb{E}[(f(x) - \mathbb{E}[\hat{f}(x)] + \mathbb{E}[\hat{f}(x)] - \hat{f}(x))^2] \\ &= \mathbb{E}[(f(x) - \mathbb{E}[\hat{f}(x)])^2] + \mathbb{E}[(\mathbb{E}[\hat{f}(x)] - \hat{f}(x))^2] + 2\mathbb{E}[(f(x) - \mathbb{E}[\hat{f}(x)])(\mathbb{E}[\hat{f}(x)] - \hat{f}(x))] \end{aligned}$$

» Da f keine Zufallsvariable sondern eine fixierte, deterministische Funktion von x ist gilt $\mathbb{E}[f(x)] = f(x)$ fällt der **letzte Term** weg und für den **ersten** ergibt sich

$$\mathbb{E}[(f(x) - \mathbb{E}[\hat{f}(x)])^2] = (f(x) - \mathbb{E}[\hat{f}(x)])^2$$

» Insgesamt erhalten wir also:

$$\text{MSE}(x) = \left(f(x) - \mathbb{E}[\hat{f}(x)] \right)^2 + \mathbb{E} \left[\left(\mathbb{E}[\hat{f}(x)] - \hat{f}(x) \right)^2 \right] + \sigma^2$$

- » **Bias Term:** Der des geschätzten Modells ("Mittelwert" über verschiedene Trainingsdatensätze) zum wahren Modell
- » **Varianz Term:** Varianz des geschätzten Modells. Wie unterschiedlich sind die geschätzten (trainierten) Modelle, wenn verschiedene Trainingsdatensätze verwendet werden. -> Sensitivität bezüglich Trainingsdaten

Methoden zur Balancierung von Bias und Varianz

- » Cross Validation
- » Regularisierung
- » Feature Selektion
- » Ensemble Methoden

Wie wähle ich die passende ML Methode?



FH KUFSTEIN TIROL
University of Applied Sciences

Welche Methode für welches Problem?

Problem verstehen (Ziel) und Klassifizieren

Datenlage checken: Menge, Qualität, Typ, Paare,...

Zusätzliche Anforderungen? Erklärbarkeit, Genauigkeit,
Performance, Compute-Ressourcen...

Problem verstehen und Klassifizieren

- » Wofür soll die Methode verwendet werden?
- » Um welche Art von Problem handelt es sich?

Klassifizierung

Regression

Clustering

Dimensionsreduktion



Welche Daten sind vorhanden?

- » Gibt es gepaarte Daten oder ungepaarte Daten oder beides?

Supervised

Unsupervised

Self-supervised

Reinforcement Learning



- » Wie ist die Menge der vorhandenen Daten?
 - Verhältnis zwischen Datenmenge und Anzahl der Features
- » Wie ist die Qualität der Daten?
 - Rauschen oder andere Fehler
- » Was ist der Datentyp, bzw. die Struktur?
 - Zeitliche Daten
 - Tabellarisch
 - Netzwerkdaten
 - Dimension: 1D (einfache Zeitreihen, Audio,...), 2D (Bilder,...), 3D (Videos, Punktwolken,...)

- » Grobe Übersicht zur Modellwahl abhängig von Datenmenge N und Feature-Zahl p
- » Achtung!, von Problem zu Problem verschieden. Das Folgende ist kein generell gültiges Rezept. Es soll nur helfen ein Gefühl für die Probleme zu entwickeln und (dem Auftraggeber) die richtigen Fragen zu stellen.
- » Oft sind zusätzliche oder ähnliche Daten vorhanden, bzw existieren Modelle die auf anderen Daten trainiert worden sind

Wenig Daten (grob: $N < 1000$ bzw. $N < p$)

- » Varianz klein halten und overfitting vermeiden
- » Gute Default-Modelle:
 - Lineare/Logistische Regression (oft regularisiert)
 - Support Vector Machine
 - Kleine Entscheidungsbäume
- » Faustregeln:
 - Lieber einfach und regularisiert als zu flexible
 - Viel Cross-Validation (z.B. 5-10-fold)
 - Feature Engineering kann mehr bringen als Modellkomplexität

Mittlere Datenmenge (grob $1000 < N < 1000000$)

- » Viele Modelle funktionieren gut. Wo liegt der Fokus:
 - Nichtlineare Effekte oder
 - Interpretierbarkeit
- » Gute Default-Modelle:
 - Gradient Boosted Trees (tabellarische Daten)
 - Random Forest
 - Regularisierte lineare Modelle als Vergleich
- » Faustregeln:
 - Für tabellarische Daten fast immer: Gradient Boosted Trees probieren
 - Wenn Interpretierbarkeit wichtig: logistische/lineare Regression + Regularisierung
 - Wenn p groß/korreliert: Feature Selection oder Regularisierung

Große Datenmenge (grob $N > 100000$)

- » Varianz wird weniger kritisch und Flexibilität lohnt sich mehr
- » Gute Default-Modelle:
 - Gradient Boosted Trees (tabellarische Daten)
 - Neuronale Netze (Deep Learning / Transfer Learning)
 - Für große lineare Probleme: SGD Minimierung des linearen Modells
- » Faustregeln:
 - Bei Text/Bild: starte mit Pretrained Models die dann finegetuned werden
 - Bei tabellarischen Daten: Neuronale Netze nur, wenn es gute Gründe gibt (passende Architektur)

Verhältnis p zu N

- » Wenn p groß und N klein:
 - Lineare Modelle
 - Starke Regularisierung
 - Feature Selektion

- » Wenn N viel größer als p :
 - Komplexere Modelle sind weniger riskant

- » **Tabellarisch:** Gradient Boosting Decision Trees als Startpunkt
- » **Text:** Transformer bei großen Datenmengen, Transfer Learning bei wenig Daten
- » **Bild/Audio:** Transfer Learning außer bei sehr speziellen Daten
- » **Zeitreihen:** Starte simpel und verwende deep learning erst bei viel Daten und/oder komplexen Mustern

- » Wenn das Rauschen sehr stark ist oder die Labels noisy sind hilft ein komplexeres Modell häufig nicht
- » Eher:
 - Robuste Modelle
 - Regularisierung
 - Bessere Labels/Features

- » Für mehr Erklärbarkeit, Stabilität und geringe Latenz:
 - Kleinere (lineare) Modelle

- » Wenn die Accuracy im Vordergrund steht und genug Daten sowie Compute vorhanden sind:
 - Komplexere Modelle

Zusätzliche Fragen:

- » Wurden schon Lösungen für das gleiche oder ein ähnliches Problem vorgeschlagen? Was funktioniert gut?
- » Gibt es ein (approximatives) physikalisches Modell für den Zusammenhang
- » Gibt es „klassische Methoden“ die man anwenden kann, um näher zur Lösung zu gelangen. Oft lässt sich das Lernproblem so stark vereinfachen!
- » Müssen die Daten zuvor bereinigt werden?

Ablauf Modellentscheidung (Vorschlag)

» **Phase 1:** Entscheidungskriterien bestimmen. Woran wird das Modell gemessen

Tasks:

- Problemtyp festlegen
- Business-/Fachziel in messbare Zielgröße übersetzen
- Einsatzkontext definieren: Batch vs. Echtzeit, Latenz, Hardware, Budget,...
- Constraints sammeln: Datenschutz, Fairness, Erklärbarkeit, Wartbarkeit,...
- Abnahmekriterien definieren: Muss-/Kann-Kriterien

Output:

1-2 Absätze

- Problemdefinition
- Klare Metrik
- Constraints
- Abnahmekriterien

Ablauf Modellauswahl (Vorschlag)

» Phase 2: Daten-/Problemcharakter bestimmen. Welche Modellfamilien passen grundsätzlich zum Daten und Problemtyp

Tasks:

- Datentyp: tabellarisch / Text / Bild / Audio / Zeitreihe / Graph
- Datensatz Größe (N,p)
- Datenqualität: Rauschen, Class Imbalance, schlechte Labels

Output:

Kurzprofil

- Problemklasse
- Datenbeschreibung
- Geeignete Modellklassen

Ablauf Modellauswahl (Vorschlag)

- » **Phase 3: Baselines!** Was soll als Baseline dienen, an der wir messen können ob komplexere Modelle einen Gewinn bringen.

Tasks:

- Dummy-Baseline: Das einfachste was man sich vorstellen kann (z.B. mean, Schwellwert,...)
- ML Baseline: Lineare Regression, Logistische Regression

Output:

Baseline Spezifikation

- Beschreibung der Baseline
- Vermutungen wie sie verbessert werden kann

Ablauf Modellauswahl (Vorschlag)

» Phase 4: Kandidaten-Shortlist nach Faustregeln. 2-4 Modellfamilien statt 20 Varianten

Tasks:

- Bestimmung sinnvoller Modelle mittels Faustregeln
- Literaturrecherche ähnliche Probleme
- Überprüfung ob die Modelle den zuvor gesammelten Anforderungen entsprechen

Output:

Kandidaten-Shortlist

- Beschreibung der Methoden
- Begründung, warum diese gewählt wurden

Was kommt danach:

- » Fairer Vergleich durch identisches Evaluierungsprotokoll
- » Grobe Suche statt Feintuning: Zuerst herausfinden welche Modellfamilie gewinnt und erst danach feintunen
- » Fehleranalyse: Warum ist das Modell gut/schlecht und was wäre die nächste Verbesserung (Bias vs. Varianz). Fehler anschauen und herausfinden was schief geht!
- » Finale Modellentscheidung: Nicht nur die beste Metrik sondern als Gesamtpaket betrachten.
- » Eventuell downsampling, Teildaten verwenden. Zuerst: simpel und schnell und erst danach erweitern

- » **Schritt 1 (45 Minuten):**
 - Überlege dir ein fiktives oder echtes Problem aus deinem beruflichen Umfeld oder persönlichem Interesse.
 - Verfasse eine kurze Beschreibung des Problems (höchstens eine halbe Seite)
- » **Schritt 2 (20 Minuten):**
 - Jeder erhält die Problembeschreibung eines Kollegen
 - Lies die Beschreibung und überlege, was noch unklar ist und welche Fragen du dem Problemsteller noch stellen musst um eine vernünftige Methodenauswahl machen zu können
- » **Schritt 3 (40 Minuten):**
 - Einzelgespräch zwischen Problemsteller und Problembearbeiter um weitere Details zu klären. Jeweils 20 Minuten
- » **Schritt 4 (90 Minuten):**
 - Modellauswahl mit Begründung. Überlege welches Modell du vorschlagen würdest und warum. Bereite 2-3 Folien vor in denen das Problem kurz beschrieben und deine Überlegungen zur Modellauswahl präsentiert werden.
- » **Schritt 5:**
 - Präsentation einzelner Problembearbeitungen bzw. Diskussion über Unklarheiten.